Gépi Tanulás – 1. Mérföldkő Dokumentáció

1.1. A Feladat típusának meghatározása: regresszió

A projekt célja zenei művek streaming-népszerűségének automatikus előrejelzése akusztikai és zenei jellemzőik alapján.

- **Célváltozó:** `song_popularity` (egész számok a [0, 100] zárt intervallumon).
- **Feladat típusa: Felügyelt tanulás – Regresszió (Supervised Regression)**.

Szakmai Indoklás (Miért regresszió és miért nem osztályozás?):

1. **Folytonos skála:** Bár a tárolt érték diszkrét egész pontszám, konceptuálisan folytonos intenzitási mutató (a lejátszási gyakoriságok és a dalfrissesség normalizált arányszáma a Spotify streaming-motorjában).
2. **Kvantitatív hibaértelmezés:** A predikció hibájának arányosnak kell lennie az eltérés mértékével. Ha a valós népszerűség 80, a 78-as becslés marginális eltérés, míg a 20-as súlyos modellhiba. Osztályozásnál e távolsági rangsor teljesen elveszne.
3. **Információvesztés elkerülése:** Bár létrehozható lenne bináris kategória (pl. ≥ 65 → *Sláger*), ez mesterséges diszkretizációt képezne, és a döntési határvonal mentén (pl. 64 vs. 65 pont) indokolatlan hibaugrást eredményezne. Emiatt a feladatot egyértelműen **regressziós feladatként** definiáljuk.

1.2. Az adatbázis forrása és méretei

- **Adatforrás:** Kaggle – *Song Popularity Dataset* (CC0 Public Domain), közvetlenül a **Spotify Web API** (`/v1/audio-features` és `/v1/tracks`) lekérdezéseiből összeállítva.
- **Méret és teljesség: 18 835 megfigyelés (sor)** és **15 attribútum (oszlop)**; **0 db hiányzó érték** (100.0% épség); **13 070 egyedi dalcím**.
- **Duplikációk: 3 909 teljes duplikált sor (20.75%)**, melyek eltávolítása után **14 926 egyedi rekord** marad az elemzéshez.
- **Célváltozó statisztikái:** Átlag: **52.99**, Medián: **56.00**, Szórás: **21.91**, Min: **0**, Max: **100**.

1.3. A numerikus változók leíró statisztikai összefoglalója

Jellemző	Típus	Min	Q25	Medián	Q75	Max	Átlag (μ)	Szórás (σ)
`song_popularity`	int64	0	40.0	56.0	69.0	100	52.99	21.91
`song_duration_ms`	int64	12 000	184 340	211 306	242 844	1 799 346	218 212	59 888
`acousticness`	float64	0.0000	0.0241	0.1320	0.4240	0.9960	0.2585	0.2887
`danceability`	float64	0.0000	0.5330	0.6450	0.7480	0.9870	0.6333	0.1567
`energy`	float64	0.0011	0.5100	0.6740	0.8150	0.9990	0.6450	0.2141
`instrumentalness`	float64	0.0000	0.0000	0.00001	0.0026	0.9970	0.0780	0.2216
`key`	int64	0	2.0	5.0	8.0	11	5.29	3.61
`liveness`	float64	0.0109	0.0929	0.1220	0.2210	0.9860	0.1796	0.1440
`loudness`	float64	-38.77	-9.04	-6.55	-4.91	+1.58	-7.45	3.83
`audio_mode`	int64	0	0.0	1.0	1.0	1	0.63	0.48
`speechiness`	float64	0.0000	0.0378	0.0555	0.1190	0.9410	0.1021	0.1044
`tempo`	float64	0.0000	98.37	120.01	139.93	242.32	121.07	28.71
`time_signature`	int64	0	4.0	4.0	4.0	5	3.96	0.30
`audio_valence`	float64	0.0000	0.3350	0.5270	0.7250	0.9840	0.5280	0.2446

A jellemzők (Audio Features) részletes ismertetése

2.1. A változók katalógusa és technikai értelmezése

Jellemző	Típus és Skála	Mérnöki / Zenei Jelentés és Eloszlási Sajátosság
`song_name`	String	A dal címe a metaadatokból. Nem egyedi azonosító (13 070 egyedi cím / 18 835 sor).
`song_popularity`	int [0, 100]	Célváltozó. Streamelésszám és időbeli frissesség normalizált kombinációja.
`song_duration_ms`	int (ms)	Időtartam ms-ban. Medián: 3.5 perc (211 306 ms). Extrém tartomány: 12 mp – 30 perc.
`acousticness`	float [0.0, 1.0]	Annak valószínűsége, hogy a felvétel tisztán akusztikus hangszerekkel készült.
`danceability`	float [0.0, 1.0]	Táncolhatóság tempóstabilitás, ritmusszabályosság és beat-erősség alapján.
`energy`	float [0.0, 1.0]	Észlelt dinamizmus és intenzitás. A gyors, hangos és sűrű dalok értéke magas.
`instrumentalness`	float [0.0, 1.0]	Annak esélye, hogy nincs énekhang (erősen jobbra ferde: a dalok 75%-ánál ≤ 0.0026).
`key`	int [0, 11]	Alaphangnem a Pitch Class kódolás szerint (0 = C, 1 = C♯/D♭, ..., 11 = B).
`liveness`	float [0.0, 1.0]	Közönségzaj érzékelése; 0.8 felett szinte biztosan élő koncertfelvétel.
`loudness`	float (dB)	Átlagos integrált hangerő decibelben. Jellemző sáv: -38.8 dB és +1.58 dB között.
`audio_mode`	int {0, 1}	Modalitás: 1 = Dúr (Major, 62.8%), 0 = Moll (Minor, 37.2%).
`speechiness`	float [0.0, 1.0]	Kimondott szavak aránya (> 0.66: beszéd/podcast, 0.33–0.66: rap, < 0.33: zene).
`tempo`	float (BPM)	Becsült ritmustempó percenkénti leütésszámban. Átlag: 121.1 BPM.
`time_signature`	int [0, 5]	Ütemmutató. Erősen 4/4 domináns (94.26%), ritka a 3/4 (4.10%) és az 5/4 (1.24%).
`audio_valence`	float [0.0, 1.0]	Zenei hangulat és pozitivitás (1.0 = vidám/euforikus; 0.0 = melankolikus/szomorú).

2.2. Változók közötti erős korrelációk és multikollinearitás

A jellemzők páronkénti Pearson-korrelációs vizsgálata markáns interakciókat tár fel az akusztikai változók között:

- `energy` ↔ `loudness` **(r = +0.7555):** Kifejezetten erős pozitív kapcsolat. A hangosabbra masterelt dalokat a jelfeldolgozó algoritmus egyúttal szignifikánsan energikusabbnak minősíti.
- `acousticness` ↔ `energy` **(r = -0.6626):** Markáns negatív összefüggés. Az akusztikus művek spektrális sűrűsége és dinamikai energiája jóval alacsonyabb a modern produkcióknál.
- `acousticness` ↔ `loudness` **(r = -0.5577):** Az akusztikus darabok átlagos hangereje jelentősen elmarad a modern többsávos stúdiópopétól.
- `danceability` ↔ `audio_valence` **(r = +0.3320):** A ritmikusabb, táncolhatóbb felvételek hajlamosabbak pozitívabb érzelmi tónust hordozni.

Modellezési konzekvencia: A standard lineáris regresszió (OLS) bizonytalanná és instabillá válhat az `energy` és `loudness` közötti erős multikollinearitás miatt.

Adatminőség-felmérés és anomália-audit

3.1. Hiányzó értékek auditja: teljes épség

Az adatbázis teljességének vizsgálata megállapította, hogy a táblázatban **egyetlen hiányzó érték (NaN / Null) sem található**:

> **Hiányzó adatok aránya = 0 / (18 835 × 15) = 0.00% (100.0% adatépség)**

A táblázat strukturálisan teljesen hiánytalan, így nincs szükség törléses vagy imputációs eljárásra hiányzó adatok miatt.

3.2. A fő adatminőségi kockázat: tömeges duplikációk

A nyers adathalmazban **3 909 sor (20.75%)** minden oszlopában teljes mértékben azonos egy másik sorral.

A duplikációk koncentrációja (Sláger-torzítás):
A nyers adathalmazban 3 909 sor (20.75%) minden oszlopában teljes mértékben azonos egy másik sorral. A duplikációk nem véletlenszerűen oszlanak el, hanem szinte kizárólag a kiugróan népszerű, globális popslágereknél halmozódnak fel:

Dalcím és Előadó (`song_name`)	Népszerűség	Duplikátumok Száma
`FEFE (feat. Nicki Minaj & Murda Beatz)`	96	**19 darab teljesen azonos sor**
`MIA (feat. Drake)`	94	**18 darab teljesen azonos sor**
`Taki Taki (with Selena Gomez, Ozuna & Cardi B)`	98	**18 darab teljesen azonos sor**
`No Stylist`	91	**17 darab teljesen azonos sor**
`Promises (with Sam Smith)`	98	**16 darab teljesen azonos sor**
`I Love It (& Lil Pump)`	99	**16 darab teljesen azonos sor**

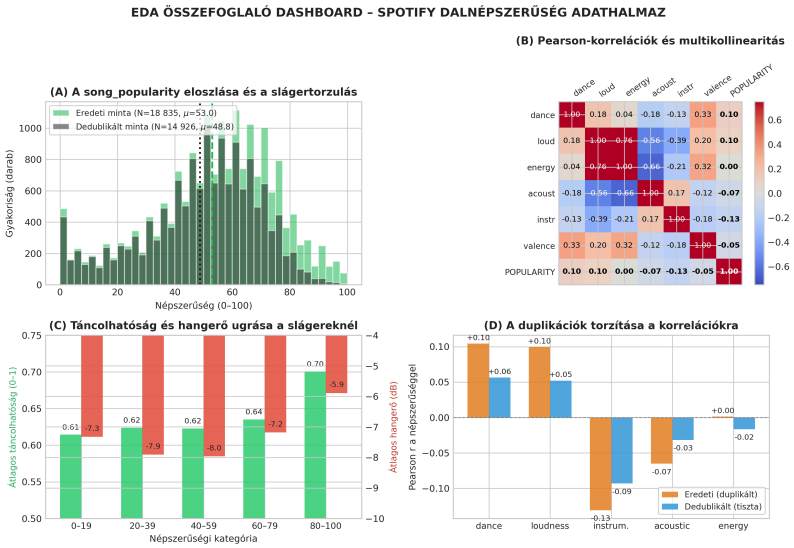
A duplikációk statisztikai és modellezési következményei:

1. **Mesterségesen eltolt átlag:** Az eredeti adathalmazban a célváltozó átlaga **52.99**, míg a duplikációk eltávolítása után **48.75**-re módosul (több mint 4.2 pont esés).
2. **Felfújt korrelációk (Pseudo-összefüggések):** Mivel a duplikált slágerek mind agresszíven táncolható, hangos dalok, a duplikációk **megduplázták a látszólagos összefüggéseket**:
   - `corr(danceability, popularity)` : nyers adaton **+0.104** → deduplikálás után mindössze **+0.056**!
   - `corr(instrumentalness, popularity)` : nyers adaton **-0.131** → deduplikálás után **-0.093**.
3. **Adatszivárgás (Data Leakage):** Ha a duplikációk kiszűrése nélkül végeznénk Train/Test felosztást, azonos sorok kerülnének mindkét halmazba, ami mesterségesen túlillesztett mérőszámokat eredményezne.
4. **Módszertani Döntés:** A gépi tanulás előtt a duplikált sorok kiszűrése (`drop_duplicates()`) kötelező; így az effektív mintaméret **14 926 egyedi rekordra** áll be.

3.3. Dalcímek nem-egyedisége és technikai anomáliák

- **Dalcímek redundanciája:** 13 070 egyedi cím jut 18 835 sorra. Például a "*Better*" cím **21 alkalommal** szerepel (népszerűsége 1 és 95 pont között szóródik). A `song_name` így nem használható kulcsként vagy bemeneti változóként.
- **Extrém időtartamok:** A minimális hossz 12 másodperc (intrók), a leghosszabb felvétel közel 30 perc (Fela Kuti: "*Army Arrangement*" – 1 799 346 ms, népszerűség: 23). Emellett megjelennek beszédek (Martin Luther King beszéde – 17.5 perc) és rock-medley-k (Rush – 20.5 perc).
- **Technikai hibák:** `time_signature == 0` (3 sor), `tempo == 0` (2 sor), `loudness > 0 dB` (7 sor, digitális clipping). Ezek medián-imputációt vagy szűrést igényelnek.

Feltáró adatelemzés (EDA) és vizualizációk



4.1. A célváltozó eloszlása és a slágertorzulás (A Panel)

A `song_popularity` eloszlása unimodális, de enyhén balra ferde (ferdeség / Skewness = -0.50). A megfigyelések zöme a [40, 75] sávban helyezkedik el (medián: 56 pont). A skála szélein torlódás látható: 0 népszerűségű dalból **272 db**, 100 pontszámúból **12 db** van. Az **(A)** panelen látható a duplikátumok torzító hatása: a zölddel jelölt nyers eloszlásban a 80–100-as tartományban mesterséges púp képződött, ami a szűrés után (fekete görbe) elsimul, és az átlag 52.99-ről 48.75-re áll be.

4.2. Korrelációk a népszerűséggel és multikollinearitás (B Panel)

A zenei jellemzők és a népszerűség közötti globális lineáris kapcsolat meglepően gyenge:

- **`instrumentalness` (r = -0.131, Spearman: -0.201):** Legerősebb negatív kapcsolat; a hangszeres művek ritkán válnak mainstream popslágerré.
- **`danceability` (r = +0.104, Spearman: +0.101):** Enyhe pozitív preferencia a táncolható ritmusok felé.
- **`loudness` (r = +0.099, Spearman: +0.137):** A hangosabb mastering enyhe versenyelőnyt jelent.
- **`energy` (r = +0.001):** Gyakorlatilag 0 kapcsolat; önmagában az energiaszint nem determinálja a sikert.

4.3. Kategóriánkénti nem-lineáris ugrás: Danceability és loudness (C Panel)

A népszerűségi kvintilisek vizsgálata **(C panel)** kritikus nem-lineáris mintázatot tár fel: a 0–79 pont közötti sávban a táncolhatóság stabilan 0.61 – 0.63 között stagnál, ám a **80–100-as csúcsslágereknél hirtelen 0.701-re ugrik**. Ugyanez a lépcsőzetes ugrás érvényesül a hangerőnél: a kevésbé népszerű sávok -7.9 dB-es átlagához képest a csúcslágerek **-5.89 dB** átlagot érnek el (átlagosan 2 dB-lel hangosabbak).

4.4. A Duplikációk torzításának hatása a változókra (D Panel)

A **(D)** panel számszerűsíti, hogy a duplikációk kiszűrése után a zenei paraméterek magyarázóereje még tovább feleződik (a táncolhatóság korrelációja 0.104-ről 0.056-ra csökken). Ez igazolja, hogy a modellezés nem építhet egyszerű lineáris regresszióra.

Módszertan, előfeldolgozás és modellezési stratégia

5.1. Mit, miért és hogyan végeztünk el? (Módszertani döntési mátrix)

Tevékenység (Mit?)	Módszer / Implementáció (Hogyan?)	Szakmai Indoklás (Miért?)
Adatminőségi Audit	Oszloponkénti null-ellenőrzés (`isna().sum()`).	Tény: 0 db hiányzó adat van, így nem szükséges mesterséges imputáció.
Duplikátum-kezelés	Teljes rekordok szűrése: `df.drop_duplicates()` .	Megszünteti az adatszivárgást és a népszerű dalok mesterséges túlsúlyát.
Anomáliák Kezelése	`time_signature == 0` , `tempo == 0` medián imputációja.	A zeneileg nonszensz értékek zavarnák a gradiens-alapú modelleket.
Identifikáció Tisztítása	`song_name` kizárása a prediktorok közül.	Nem egyedi azonosító, túlillesztést okozna a magas kardinalitás miatt.

5.2. Modellezési architektúra és algoritmusválasztás

Mivel a célváltozó és a zenei jellemzők közötti globális lineáris kapcsolat gyenge ($|r| \leq 0.13$), az egyszerű lineáris regresszió várhatóan alacsony magyarázó erejű ($R^2 < 0.05$) lesz. Emiatt többlépcsős architektúrát építünk fel:

```
[Baseline Modell]          [Lineáris Regularizált]         [Nem-lineáris Fa-együttesek]
 Dummy Regressor      --->      Ridge / ElasticNet     --->   Random Forest & LightGBM
(Átlag/Medián jóslás)       (Multikollinearitás védve)         (Interakciók és küszöbértékek)
```

1. **Baseline modell:** `DummyRegressor(strategy='mean')` biztosítja az abszolút viszonyítási alapot.
2. **Lineáris benchmark:** `Ridge` és `ElasticNet` regresszió az `energy` és `loudness` közötti multikollinearitás stabil kezelésére.
3. **Nem-lineáris fa-együttesek (Fő modellek):**
   - **Random Forest Regressor:** Képes felderíteni a küszöbérték-szerű mintázatokat (pl. magas siker csak kiugró táncolhatóság mellett).
   - **LightGBM / XGBoost Regressor:** Gyors, grádiens alapú döntési fa együttes, amely kiválóan kezeli a ferde eloszlásokat és a komplex interakciókat.

5.3. Validációs keretrendszer és értékelési metrikák

- **Keresztvalidáció: 5-Fold Cross-Validation** a tiszta, deduplikált adathalmazon (N = 14 926).
- **Értékelési Metrikák:**
  - **RMSE (Root Mean Squared Error):** Szigorúan bünteti a nagy hibákat (pl. slágerek alulbecslését).
  - **MAE (Mean Absolute Error):** Közvetlenül pontszámban értelmezhető átlagos abszolút tévedés.
  - **R^2 (Determinációs együttható):** A variancia magyarázott hányada a baseline-hoz képest.

5.4. Záró összegzés és tanulságok

Az 1. mérföldkő elemzése bebizonyította, hogy a dalok akusztikai profilja önmagában nem predesztinálja a népszerűséget: a táncolhatóság és a hangerő szükséges, de nem elégséges feltétele a sikernek (marketing és playlist-elhelyezés nélkül). Ugyanakkor kimutatható egy egyértelmű "sláger-profil": a 80 feletti népszerűségű számok szignifikánsan táncolhatóbbak és hangosabbak az átlagnál.