Tartalomjegyzék:

Leírás

- A feladat típusának meghatározása (klasszifikáció / regresszió)
- Az adatbázis bemutatása
- Az adatbázis forrásának megadása
- A jellemzők jelentésének ismertetése
- Az adatminőség felmérése
- Az adatok vizualizálása és megismerése

Beadandó

- Dokumentáció: maximum 5 oldalas PDF
- A dokumentáció térjen ki arra, hogy **mit, miért és hogyan** végeztek el.

Értékelés

- A feladat helyes meghatározása: **2 pont**
- A jellemzők megfelelő bemutatása: **2 pont**
- Az adatminőség megfelelő felmérése: **2 pont**
- Megfelelő és informatív vizualizációk: **2 pont**
- A dokumentáció minősége: **2 pont**

Összesen: 10 pont

1. A feladat típusa: regresszió

A `song_popularity` a célváltozó, értéke **0 és 100 közötti egész szám**:

2. Az adatbázis legfontosabb számai

Tulajdonság	Érték
Sorok száma	**18 837**
Oszlopok száma	**15**
Numerikus változók	14

Szöveges változó	1 (`song_name`)
Egyedi dalnevek	**13 070**
Hiányzó értékek	**2**
Teljesen duplikált sorok	**3 909**
Egyedi sorok duplikációk eltávolítása után	**14 928**
`song_popularity` átlaga	**52,99**
Medián	**56**
Minimum	**0**
Maximum	**100**

A változók nagy része a Spotify által használt audio feature-ökhöz kötődik. A Spotify-féle jellemzők jelentése például a danceability, energy, acousticness, instrumentalness, liveness, speechiness és valence esetében szabványosított.

3. A legérdekesebb összefüggés: a népszerűség és a danceability

A Pearson-korrelációkat kiszámolva:

Jellemző	**Korreláció `song_popularity`-vel**
danceability	**+0,105**
loudness	**+0,101**
time_signature	+0,037
speechiness	+0,022
energy	+0,002
audio_mode	−0,005
key	−0,013
duration	−0,015

tempo	−0,021
liveness	−0,038
audio_valence	−0,052
acousticness	−0,065
instrumentalness	**−0,130**

Ez önmagában nagyon jó megfigyelés:

> **A dataset alapján a népszerűség és a zenei jellemzők között általában nincs erős lineáris kapcsolat.**

A legerősebb pozitív kapcsolat a **danceability**, a legerősebb negatív pedig az **instrumentalness**.

Viszont még ezek is gyengék. Ez azért érdekes, mert azt mutatja, hogy **egy dal pusztán akusztikai jellemzőiből nem lehet egyszerűen megmondani, mennyire népszerű**.

Még érdekesebb: Spearman-korreláció

Spearman esetén:

- danceability: **+0,102**
- loudness: **+0,137**
- instrumentalness: **−0,200**

Az instrumentalness tehát monoton kapcsolat szempontjából valamivel erősebben kapcsolódik a popularityhöz, mint Pearson alapján.

---

4. A népszerűbb dalok tényleg táncolhatóbbak

Ha a népszerűséget kategóriákra bontjuk:

Popularity	Dalok száma	Átlagos danceability
0–19	1 770	0,614
20–39	2 721	0,624
40–59	6 324	0,623
60–79	6 320	0,635
80–100	**1 702**	**0,701**

Ez szerintem az egyik **legjobb ábra a beadandóba**.

A 80–100 közötti popularity kategóriában a danceability átlagosan **0,701**, míg a legkevésbé népszerű kategóriában csak **0,614**.

Tehát:

> A nagyon népszerű dalok ebben az adathalmazban átlagosan lényegesen táncolhatóbbak.

Ez már vizuálisan is jól bemutatható egy **boxplot vagy kategóriánkénti átlagos oszlopdiagram** segítségével.

Fontos azonban, hogy ez **összefüggés, nem ok-okozati kapcsolat**.

---

5. A loudness is érdekes

Ugyanezekben a kategóriákban az átlagos loudness:

Popularity	Átlagos loudness
0–19	−7,34 dB
20–39	−7,91 dB
40–59	−7,97 dB
60–79	−7,18 dB

80–100 −5,89 dB

A 80–100 popularity-jű dalok tehát átlagosan **jóval hangosabbak**.

Ez szépen összecseng azzal, hogy a loudness és a popularity Pearson-korrelációja **+0,101**.

---

6. Nagyon érdekes: az energy önmagában szinte semmit nem magyaráz

Az `energy` és `song_popularity` korrelációja:

r = 0,00194

Gyakorlatilag nulla.

Ez azért érdekes, mert az `energy` és `loudness` között viszont:

r = 0,755

Tehát:

energy ↔ loudness: erős kapcsolat
energy ↔ popularity: gyakorlatilag nincs kapcsolat

Ez jó példa arra, hogy **egy változó és egy másik változó közötti erős kapcsolat nem jelenti azt, hogy bármelyikük önmagában erősen összefügg a célváltozóval**.

---

7. Az acousticness és energy kapcsolata

Egy másik nagyon látványos összefüggés:

`acousticness` ↔ `energy`: **r = −0,662**

Vagyis az akusztikusabb számok általában kevésbé energikusak ebben az adathalmazban.

Ugyanakkor:

`acousticness` ↔ `song_popularity`: **r = −0,065**

Ez megint azt mutatja, hogy egy nagyon jól látható zenei kapcsolatból **nem következik erős popularity-kapcsolat**.

---

8. A legnagyobb adatminőségi probléma: rengeteg duplikáció

Ez szerintem **kötelező elem a beadandóban**.

A 18 837 sorból:

3 909 sor teljesen azonos egy másik sorral.

Ez:

20,8%

Tehát az adatállomány több mint **ötöde teljesen duplikált**.

Ha eltávolítjuk ezeket:

18 837 → 14 928 sor

Ez önmagában nagyon fontos adatminőségi megállapítás.

És van még egy érdekes következménye

Az eredeti adatokban:

- danceability ↔ popularity: **0,105**
- instrumentalness ↔ popularity: **−0,130**

Duplikációk eltávolítása után:

- danceability ↔ popularity: **0,057**
- instrumentalness ↔ popularity: **−0,092**

Vagyis a duplikációk **észrevehetően felerősítik az összefüggéseket**.

Ez már nagyon jó ML-es megfigyelés:

> **A duplikált megfigyelések miatt a modell és a statisztikai elemzés bizonyos mintázatokat a valóságosnál erősebbnek érzékelhet.**

Ezt én mindenképpen belevenném a dokumentációba.

---

9. A `song_name` nem egyedi azonosító

13 070 különböző név van, miközben 18 835 sorban van név.

Például:

- **Better** – 21 alkalommal
- **FEFE** – 19
- **Taki Taki** – 18
- **MIA** – 18
- **No Stylist** – 17

Ez azt jelenti, hogy:

> **A `song_name` nem használható megbízhatóan egyedi dalazonosítóként.**

És van egy még érdekesebb jelenség.

A `Better` cím például több különböző popularity értékkel is szerepel:

> 21 rekord, popularity értékek között **1–95** is előfordul.

Ez valószínűleg különböző felvételek/verziók vagy forrásbeli ismétlődések jelenlétére utalhat, ezért a név önmagában nem elegendő az azonosításhoz.

---

10. Két hiányzó `song_name` van

Ez különösen érdekes, mert **csak a `song_name` oszlopban van hiányzó adat**.

Összes hiányzó:

> **2 / 18 837 = 0,011%**

Tehát a hiányzó adatok mennyisége összességében nagyon kicsi.

Viszont a két sor:

popularity	duration
0	1 799 346 ms
100	1 799 346 ms

Ez érdekes, mert ugyanahhoz a rendkívül hosszú, kb. **30 perces** időtartamhoz két szélsőséges popularity érték tartozik.

Az egyik hiányzó nevű rekord tehát:

- popularity = 0
- duration ≈ **30 perc**

a másik:

- popularity = 100
- duration ≈ **30 perc**

Ez adatminőségi szempontból mindenképpen említésre méltó.

---

11. Vannak nagyon furcsa hosszúságú "dalok"

A `song_duration_ms`:

- minimum: **12 000 ms**
- medián: **211 306 ms**
- maximum: **1 799 346 ms**

Vagyis:

12 másodperc → közel 30 perc

A legnagyobb értékek között például szerepel:

- *Army Arrangement* – 1 799 346 ms
- *Play* – 1 355 938 ms
- *2112: Overture / The Temples Of Syrinx / Disco...* – 1 233 666 ms
- *I Have a Dream - The Complete Speech* – 1 047 933 ms
- *Autobahn - 3-D* – 866 889 ms

Ez azt sugallja, hogy az adatbázis nem feltétlenül csak klasszikus, néhány perces popdalokat tartalmaz, hanem **hosszú zenei műveket, beszédfelvételeket és egyéb audioanyagokat is**.

Ez azért fontos, mert a `song_name` elnevezés kissé félrevezető lehet.

---

12. A popularity eloszlása

A popularity:

- átlag: **52,99**
- medián: **56**
- szórás: **21,91**
- minimum: 0
- maximum: 100
- 0 érték: **273**
- 100 érték: **13**

A medián magasabb az átlagnál, ami összhangban van azzal, hogy az eloszlás kissé balra ferde.

A legtöbb adat:

> **40–79 közé esik.**

Ezért egy egyszerű histogram nagyon jól bemutatná a célváltozó eloszlását.

---

13. Az audio_mode szinte semmit nem számít

Az `audio_mode`:

- 0 = minor
- 1 = major

A datasetben:

- major: **11 832 (62,8%)**
- minor: **7 005 (37,2%)**

A popularity átlaga:

- minor: **53,13**
- major: **52,91**

Gyakorlatilag ugyanaz.

Ez egy jó negatív eredmény:

> **Ebben az adathalmazban a major/minor mód nem mutat érdemi kapcsolatot a népszerűséggel.**

---

14. A 4/4-es ütem dominál

A `time_signature` eloszlása:

Ütemmutató	Darabszám	Arány
4	17 754	**94,25%**
3	772	4,10%
5	234	1,24%
1	73	0,39%
0	4	0,02%

Ez önmagában is nagyon jó vizualizációs lehetőség.

A dataset tehát **rendkívül erősen 4/4-domináns**.

---

15. A tempo meglepően kevéssé kapcsolódik a popularityhöz

A tempo és popularity korrelációja:

> **−0,021**

Gyakorlatilag nincs lineáris kapcsolat.

Ez érdekes, mert intuitívan gondolhatnánk, hogy a gyorsabb, táncolhatóbb zenék népszerűbbek. A dataset alapján azonban a **tempo önmagában nem jó indikátora a popularitynek**.

A danceability viszont valamennyire összefügg a popularityvel.

Ez két jó változó összehasonlítása lehet egy scatterplot-párban:

- `tempo` vs. `song_popularity`
- `danceability` vs. `song_popularity`

---

16. Instrumentalness – az egyik legjobb jelölt

Az `instrumentalness` popularity-korrelációja:

> **−0,130 Pearson**
>
> **−0,200 Spearman**

Ráadásul az instrumentalness nagyon szélsőséges eloszlású:

- medián: **0,000011**
  75. percentilis: **0,00257**
- maximum: **0,997**

Tehát a datasetben **rengeteg olyan dal van, amelynek instrumentalness értéke gyakorlatilag nulla**, miközben néhány szám nagyon magas értéket kap.

Ezért ezt nem biztos, hogy sima scatterplottal érdemes bemutatni. Jobb lehet például:

instrumentalness log-skálás histogram, vagy popularity-kategóriák szerinti boxplot.